

Tarea #: 2

Tema: Regresión

Fecha entrega: 11:59 pm 17 de octubre 2024

Objetivo: Aplicar los conceptos de KNN, regresión y GBM en datos reales.


Entrega: Crear una rama utilizando el mismo repositorio de la tarea 1, crear otra carpeta llamada tarea 2, solucionar el problema y crear un pull request sobre la master donde me debe poner como reviewer (entregas diferentes tienen una reducción de 0.5 puntos).









1 Regresión (60%)






Utilizar kaggle para descargar la base

<https://www.kaggle.com/t/efa882e3a6d94bf799278c56ef3c8317> , el caso de uso es que basado en las condiciones del estudiantes vamos a predecir el puntaje que tendrá en las pruebas del saber en lecture critica "PUNT_GLOBAL".


1. Realizar la exploración de los datos correlación, scatter plots, boxplots e histogramas:







Distribución de las variables dummy de ESTU_PRGM_ACADEMICO



1.1. ¿Qué variables son importantes para predecir el valor?

- 2 - ESTU_FECHANACIMIENTO
- 3 - ESTU_DEPTO_RESIDE
- 4 - ESTU_AREARESIDE
- 5 - ESTU_TITULOBTENIDOBACHILLER
- 6 - ESTU_GENERO
- 7 - ESTU_COMOCAPACITOEXAMENSB11
- 8 - ESTU_TIPODOCUMENTOSB11
- 9 - FAMI_EDUCACIONPADRE
- 10 - FAMI_EDUCACIONMADRE
- 11 - FAMI_OCUPACIONPADRE
- 12 - FAMI_OCUPACIONMADRE
- 13 - FAMI_TIENEINTERNET
- 14 - ESTU_HORASSEMANTRABAJA
- 15 - ESTU_VLRULTIMOSEMESCURSADO
- 16 - ESTU_PRGM_ACADEMICO

1.1. Existen nulos?, ¿cómo se deben imputar?

En las variables categóricas, si hay valores faltantes, estos se llenarán con los datos de la categoría que más aparece(MODA), luego se crearan dummies para las columnas y se eliminaran las columnas no necesarias, se hace tanto en datos de entrenamiento como en los de test para poder usarlas en un análisis posterior, para variables numéricas lo que se hace es rellenar los valores faltantes con la media (promedio).

2. Divida los datos en training y testing
- 2.1. Aplique las transformaciones más importantes a los datos. (Hint calcular la edad basada en la fecha de nacimiento, agrupar variables categóricas con mucha cardinalidad en grupos).
- 2.2. Entrenar un modelo de regresión
- 2.3. ¿Cuál es el mejor R squared?Cuál es el MAPE y el MSE.
- 2.4.

```
Coeficiente de determinación  $R^2$ : 0.3120445634423703  
Error porcentual absoluto medio (MAPE): 19783856825415.684  
Error cuadrático medio (MSE): 379.21760366002314
```

3. Remueva las variables que nos son relevantes
4. Utilizando los datos de test medir el MAPE y el MSE de test. Qué tan diferentes son las métricas de training. (El menor error del grupo tiene un +1

5. Describa en palabras que dice el modelo cuales son los principales hallazgos.

Coeficiente de determinación (R^2)

En este caso, el R^2 es **0.31**, lo que indica que el modelo solo está explicando el **31%** de la variabilidad en el puntaje global (PUNT_GLOBAL). Esto sugiere que el modelo no está siendo muy efectivo para predecir correctamente los valores.

Error porcentual absoluto medio (MAPE)

El **MAPE** es **19783856825415.684**, lo cual es extremadamente alto, lo que indica que el modelo tiene grandes errores en sus predicciones.

Error cuadrático medio (MSE)

El **MSE** es **379.22**, lo que nos dice que el error promedio al cuadrado de las predicciones es de aproximadamente **379**. Un MSE más bajo indica un mejor rendimiento del modelo.

17 Crear un modelo de KNN (20%)

Utilizar los datos para crear un modelo de KNN que permita predecir el puntaje por estudiante. Utilizar kaggle para descargar la base <https://www.kaggle.com/t/efa882e3a6d94bf799278c56ef3c8317> y las mismas transformaciones de punto anterior

- 1) Hacer pruebas con 5, 10, 20 y 30 vecinos. Seleccione el numero de vecinos basado en el error de test MSE.

```
... MSE con 5 vecinos: 453.95408178527623
MSE con 10 vecinos: 419.4937640970415
MSE con 20 vecinos: 407.5644615453648
MSE con 30 vecinos: 405.9491958412689
El mejor número de vecinos es 30 con un MSE de 405.9491958412689
```

- 2) Describa cual es mejor modelo entre la regresion o el knn.

- El mejor modelo fue con 20 variables que se utilizaron fue el knn con K = 30

```
MSE con 5 vecinos: 453.95408178527623
MSE con 10 vecinos: 419.4937640970415
MSE con 20 vecinos: 407.5644615453648
MSE con 30 vecinos: 405.9491958412689
El mejor número de vecinos es 30 con un MSE de 405.9491958412689
```

18 Crear un modelo de GBM (20%)

Entrenar un modelo de GBM y hacer la prediccion. Cual es el MSE y MAPE para train y test.

```
Error cuadrático medio en entrenamiento (MSE): 408.01594915444775
Error porcentual absoluto medio en entrenamiento (MAPE): 8147006302617.829
Error cuadrático medio en prueba (MSE): 412.2192074862684
Error porcentual absoluto medio en prueba (MAPE): 19122932537627.492
Archivo 'prediccion_gbm.csv' generado exitosamente.
```